


Sustainable AI Gateway

Prompt-Vorabanalyse für Kosten, Fußabdruck, Compliance und Modellwahl

Team: EnKeMa

12.09.2026



Projekt- / Teamarbeit

Tools

- ✓ Claude Code und Codex
- ✓ VSC
- ✓ GitHub

Regelwerk (AGENTS.md)

- ✓ Coding Rules
- ✓ Sicherheit
- ✓ Testabdeckung
- ✓ Barrierefreiheit

Organisation / Kommunikation

- ✓ Themen/Ziele (Tasklist.md)
- ✓ Kommunikation (Chats, Issue Tracker, Change-Logs)

Entwicklungs- und Testumgebung

- ✓ Lokale Umgebung (Windows und MacOS)
- ✓ MacBook für Präsentation

Projektthema / Systemsicht





ABB. 1 – SYSTEMKONTEXT

Gateway Flow Chart

- 1) Dashboard » Prompt-Eingabe, Ampel/Empfehlung anzeigen
- 2) API-Routen Empfang & Validierung » Anfrage entgegennehmen, Prompt validieren
- 3) Prompt-Analyse » Ollama bewertet Komplexität, Sensitivität, Kategorie
- 4) Compliance Stufe 1 » Regelbasierte personenbezogene Daten und Muster-Prüfung, Score berechnen
- 5) Compliance Stufe 2 » Semantische Guardian-Prüfung auf Datenschutzrisiken
- 6) Kennzahlen-Ermittlung » Token, Kosten, Energie/CO2 → Modellkatalog (Preis-, Kontextfenster- und Eco-Parameter je Modellklasse)
- 7) Empfehlung » Modellklasse vorschlagen, kein Auto-Dispatch → Modellkatalog (Preis-, Kontextfenster- und Eco-Parameter je Modellklasse)
- 8) Versand » Providerliste (Ollama, Anthropic, OpenAI-kompatibel), Nach Bestätigung an gewählten Provider senden + Logging + Feedback (Nutzung protokollieren, Kalibrierung Verhältnis)
- 9) Ziel-LLM » extern oder lokal



Modul: Compliance Check

Compliance Stufe 1

„Regelbasiert“

*Mustererkennung, Prüfsummen
(IBAN, Kreditkarte...)*

Beispiel:

Prompt	Compliance
Ich möchte meine DE02300606010002474689 an einen Käufer auf eBay schicken. Formuliere mir eine Mail dazu	82/100 Musterprüfung (Stufe 1): IBAN Stufe 1 + 2 geprüft

Compliance Stufe 2

„Semantisch“

*Lokales Guardian-Modell für Fälle
ohne Muster*

Beispiel:


Prompt	Compliance
Person A aus der Abteilung Vertrieb ist heute krank gemeldet. Formuliere eine kurze Info an das Team.	79/100 Musterprüfung (Stufe 1): keine Kennungen gefunden · Kontextprüfung (Stufe 2): mögliches Datenschutz- oder Vertraulichkeitsrisiko erkannt Stufe 1 + 2 geprüft

Modul: Fußabdruck (4 Vertrauensstufen)

EcoLogits

„Bestätigt“

Anbieter/Modell in DB



Näherung

„Berechnet“

Katalog- oder Providerparameter

(nicht EcoLogits-DB bestätigt)



Lokale CPU Schätzung

„Erfasst“

$psutil\text{-Auslastung} \times TDP$
während echtem
Ollama-Send




Grobe Schätzung

„Vereinfacht“

Fallback auf Lineare Formel



Modul: Modell-Empfehlung



- Empfehlung aus Sensitivität, Komplexität, gewähltem Modus und Kontextlänge
- Sensibel oder rote Ampel → bevorzugt lokal, kein Datenabfluss außer bei explizitem Cloud-Modus
- Sonst abhängig von Modus: lokal, EU, oder Cloud (Haiku/Sonnet je nach Komplexität)
- Empfehlung ≠ Versand → Nutzer bestätigt immer manuell, d.h. kein Auto-Dispatch

Prompt analysieren

Prompt

Beschreibe deine Aufgabe ...

0 Zeichen

Zielmodus

Lokales Ollama-Modell

☒ Prompt nach Verarbeitung im Browser verwerfen

Prompt analysieren

Analyse abgeschlossen.

Analyse und Versand sind getrennt. Externe Übertragung erfolgt nie automatisch.

API

Ich bin ein großes Sprachmodell und wurde vom Google DeepMind-Team entwickelt.

Ich habe keinen Geburtstag, wie Menschen, und meine Entwicklung ist kontinuierlich.

Gibt es etwas anderes, über das ich Ihnen helfen kann? 😊

Kosten dieser API-Antwort: € 0.000000

Du

welches Jahr haben wir?

A

Das Jahr ist 2023. 😊

Kosten dieser API-Antwort: € 0.000000

Nächste Nachricht

Schreibe eine Folgefrage ...

Fußabdruck schätzen

Nachricht senden

Compliance-Prüfung (Nachricht + Verlauf): 100/100 · GREEN

Treffer: keine lokalen Treffer

€ 0.000000

Input

68 Token · € 0.000000

Output

6 Token · € 0.000000

Gesamtkosten

€ 0.000000

Gesamttoken

136

Fußabdruck dieser Unterhaltung



Wasser · —

CO₂e · 0.0234 g

Energie · 0.0669 Wh

Referenz: 150 mL Tasse heißer Tee.

Letzte Runde: Lokale CPU-Schätzung

Mögliche Verbesserungen / Features

- Eigenes lokales Modell ("Transformer Lite") statt Ollama-Prompting
- API-Schlüsselverwaltung härten: aktuell symmetrisch (Fernet) — Angriffsfläche ist APP_ENCRYPTION_KEY + Zugriff auf instance/gateway.db zusammen
 - Schlüssel ins OS-Credential-Store (Windows Credential Manager/macOS Keychain) statt .env
 - Perspektivisch z.B. Vault/KMS für Produktivbetrieb
- RAG-Demonstrator für Compliance-Quellenverweis (closed book → open book; Bsp. DSGVO Hinweis zum Compliance-Fund)
- Auto-Pilot: automatische Auswahl + automatischer Versand basierend auf Kern-Requirements (Compliant, Best Fit, Carbon, Lokal-first)
- EcoLogits-Version automatisiert aktuell halten (Dependabot) — sonst fallen neue Modelle länger als nötig auf „Näherung" statt „Bestätigt" zurück
- Update technische Dokumentation mit Hardware-Empfehlung für produktiven Einsatz

Fragen & Diskussionen

Sustainable AI Gateway